基于 12 家家电上市公司 2025 年年度报告的问答知识库

复旦 · MF70050.01 人工智能与数据分析 · 作业 3（方向 A） | 语料：12 份年报全文，共 2,544 页、18,671 个知识块

12 家	18,671	78.8%	100%
家电上市公司 2025 年报	知识块（正文 11,737 + 表格 6,934）	十题关键数值命中（26/33）	回答带页码级出处

一、做了什么

把美的、格力、海尔智家、海信家电、TCL智家、长虹美菱、老板电器、万和电气、火星人、苏泊尔、九阳股份、莱克电气 12 家公司 2025 年年度报告（巨潮资讯网原文 PDF）做成一个可提问的问答知识库，答案必须给出处、可点回年报原文对应页。

二、三个关键做法

- **表格语义化切块（最关键）。**年报 PDF 直接抽取的表格是「空单元格 + 竖线」，块里既没有公司名也没有年份——实测含「美的营业收入 456,451,731」的那一块，BM25 排不进前 200、向量排到第 607。改为把表格重排成 `「列名: 数值；列名: 数值」` 的自然语言，并给每块加上「公司（代码）报告名 | 章节 | 第 N 页」前缀后，同一块立刻排到第 1。
- **混合检索 + 查询改写。**BM25（k1=1.5, b=0.75）与向量（本地 ONNX BGE-small-zh，512 维）双路召回，用 RRF 融合；提问先经大模型改写成检索式——口语化的「去年赚了多少钱」才能命中「归母净利润」。
- **按问题类型切换检索策略。**问「为什么下降」时把候选限定在「行业情况 / 主营业务分析」等叙述性章节（避免被财报附注挤掉）；问「谁最高谁最低」这类跨公司全景题时逐家召回再汇总，避免只召回两三家。

三、评测（10 题，题目与参考答案先冻结、答案逐条对照年报原文核对）

题号 / 类型	命中	耗时	题号 / 类型	命中	耗时
Q01 单公司·数字	3/5	2.3s	Q06 经营解释（跨段归纳）	3/3	2.9s
Q02 单公司·数字	2/3	2.1s	Q07 研发投入（表+比率）	1/2	1.5s
Q03 分季度（跨列读取）	8/9	1.9s	Q08 跨公司全景	2/2	4.0s
Q04 跨表·比率	1/2	1.6s	Q09 跨公司全景	3/4	2.7s
Q05 口语化提问	3/3	1.6s	Q10 库外题（应拒答）	正确拒答	1.2s

「命中」= 参考答案中的关键数字有几个出现在模型答案里（换单位、换口径的同一数字算命中）。**合计 26/33 = 78.8%**。未命中的 7 个全部是题干没有问到、只是参考答案里顺带列的对照数字（如上期数、扣非净利），并非答错。

四、三个结论

- **切块方式比模型更决定成败。**同样的检索与生成，只改表格的文本化方式，就把一道关键题从「完全检索不到」变成「排第一」。PDF 表格进知识库，必须先还原语义。
- **检索要按问题类型分流。**数字题走表格块、原因题走叙述章节、全景题逐主体召回——一套统一的 Top-K 无法同时满足这三类。
- **口径必须写进提示词。**「营业总收入」与「营业收入」（美的 4,585 亿 vs 4,564.52 亿）、「净利润 / 归母净利润 / 扣非净利润」在同一份年报里并存，不显式约束，模型就会串口径。
- **答不出要敢说答不出。**库外题（2026 半年报）正确返回「资料中未找到」，而不是编造数字——这是可用性的底线。

五、局限与下一步

答案的完整性受限于「块内可见信息」：跨页表格、需要相减得出的比率，仍可能漏答。下一步打算把「主要会计数据」等标准表结构化成键值表，让数值类问题走查表而非检索；并把评测集从 10 题扩到 50 题，按题型分别统计。此外本地 ONNX 模型（512 维）在长表述上的分辨力弱于大型嵌入模型，是当前检索上限之一。